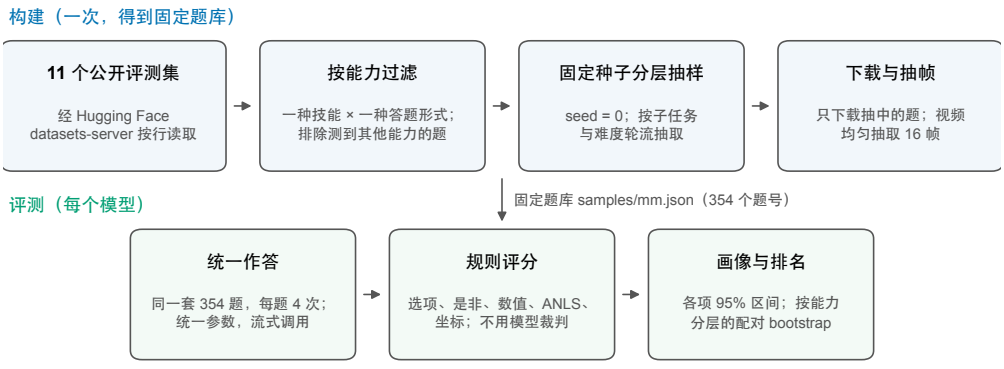

构建（一次，得到固定题库）
11 个公开评测集
经 Hugging Face datasets-server 按行读取
按能力过滤
一种技能 × 一种答题形式；排除测到其他能力的题
固定种子分层抽样
seed = 0；按子任务与难度轮流抽取
下载与抽帧
只下载抽中的题；视频均匀抽取 16 帧
固定题库 samples/mm.json（354 个题号）
评测（每个模型）
统一作答
同一套 354 题，每题 4 次；统一参数，流式调用
规则评分
选项、是非、数值、ANLS、坐标；不用模型裁判
画像与排名
各项 95% 区间；按能力分层的配对 bootstrap