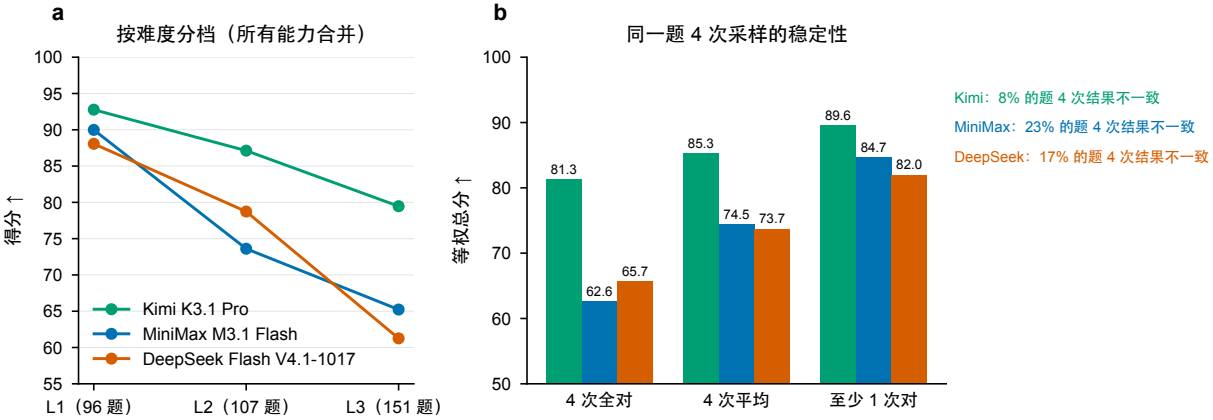
a
按难度分档（所有能力合并）
得分 ↑
100
95
90
85
80
75
70
65
60
55
Kimi K3.1 Pro
MiniMax M3.1 Flash
DeepSeek Flash V4.1-1017
L1（96 题）
L2（107 题）
L3（151 题）
b
同一题 4 次采样的稳定性
等权总分 ↑
100
90
80
70
60
50
81.3
62.6
65.7
85.3
74.5
73.7
89.6
84.7
82.0
4 次全对
4 次平均
至少 1 次对
Kimi：8% 的题 4 次结果不一致
MiniMax：23% 的题 4 次结果不一致
DeepSeek：17% 的题 4 次结果不一致