mmBench：能力正交的多模态大模型评测基准

技术报告

Albert Huang

BAI AI Lab

https://github.com/BAI-AI-Lab/mmBench

2026 年 10 月 31 日

摘要

多模态大模型的评测通常把多种能力混在同一套题、同一个总分里：一道图表题可能同时考读字、读图和推理，一个总分也无法说明模型强在哪里、弱在哪里；而只报告单次运行的排名，又难以判断模型之间的差距是否真实。本文提出 mmBench，一个以能力画像为先、同时给出可量化排名的多模态评测基准。mmBench 把多模态能力划分为学科推理、视觉感知、图表、文档、空间、界面定位与视频时序 7 项，每项只考查一种技能、只使用一类答题形式，并在抽题时排除会考到其他能力的题；最终按固定随机种子从 11 个公开评测集中抽取 354 道题。所有题目用确定的规则评分，不使用模型裁判；每个模型每题作答 4 次，各项能力给出按题重抽样的 95% 区间，两两比较采用按能力分层的配对 bootstrap。我们评测了 Kimi K3.1 Pro、MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 三个模型：Kimi K3.1 Pro 以 85.3 分居首，领先另外两个模型约 11 分；后两者总分只差 0.7 分、统计上无法区分，能力画像却明显不同——MiniMax M3.1 Flash 在界面定位上高出 21.0 分，DeepSeek Flash V4.1-1017 在空间上高出 11.5 分。按国内站标价，完成全部评测的费用分别约为 193 元、14 元与 28 元，三个模型每次调用的平均输出长度相差 5 倍。代码与题号清单已开源。

1 引言

多模态大模型已经能够回答学科问题、读懂图表与文档、在屏幕截图上操作界面，评测它们的基准也越来越多。然而，一个有用的评测不仅要回答“哪个模型更好”，还要回答“好在哪里”“差距是否可信”。我们认为现有的综合性评测在这三方面存在共同的问题：

- **能力相互混杂。** 同一道题往往同时考查多种能力：学科题的图片可能是一张表格，图表题需要先读出图中的文字，界面题的目标可能是一段文字。分数低时，难以判断是哪一种能力不足；把这样的题合成一个总分，模型之间不同的能力结构也随之被抹平。
- **评分引入额外噪声。** 开放式答案常交给另一个模型判断对错，评分本身随裁判模型的版本与提示词变化，难以复现。
- **排名缺少不确定性。** 多数评测只报告单次运行的点估计，几分之差也被排成先后；而在几百道题的规模上，这样的差距常常在抽样误差之内。

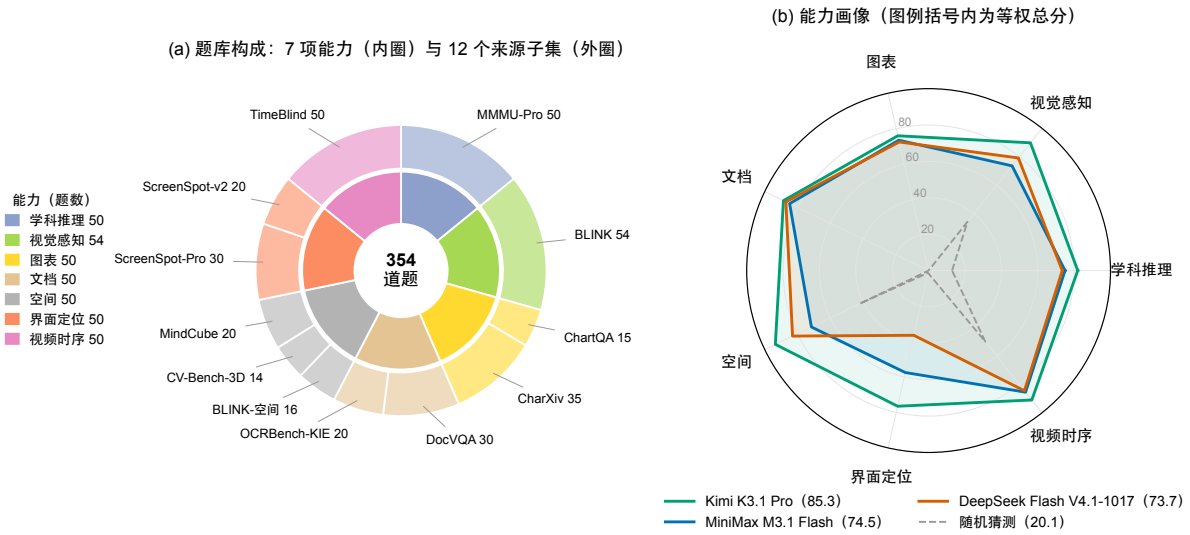


图 1　**mmBench** 概览。(a) 题库构成：内圈为 7 项能力及其题数，外圈为 12 个来源子集（BLINK 拆为感知与空间两部分）。(b) 三个模型的能力画像，虚线为随机猜测的期望得分。Kimi K3.1 Pro 在每一项上都处于最外圈；MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 总分几乎相同，但在界面定位和空间两项上方向相反。

针对这些问题，我们构建了 mmBench（图 1）。它的核心思路是先定义互不重叠的能力，再从已有的公开评测集中挑选只考查该能力的题，并用统计方法明确区分“能分出高低的差距”与“分不出的差距”。本文的主要贡献如下：

- 我们提出了一种能力正交的题库设计：7 项能力各对应一种技能和一类答题形式，并在抽题时逐题排除会考到其他能力的题，得到一个可复现的 354 题固定题库。
- 我们给出了同时支持能力画像与排名的评测协议：规则评分、每题 4 次采样、按题重抽样的区间、按能力分层的配对比较，以及“只有显著领先才分名次”的排名规则；并报告了这套题量所能分辨的最小差距。
- 我们用 mmBench 评测了三个国产多模态模型，分析了它们的能力画像、难度梯度、采样稳定性，以及以真实计费 token 计算的成本与效率。

2　相关工作

综合性多模态评测。　MMBench [1] 以选择题覆盖约 20 个能力维度；MMMU [2] 收集了大学水平的多学科图文问题，MMMU-Pro [3] 进一步过滤掉只看文字就能回答的题、把选项扩充到 10 个，并加入把题目印在图片里的版本。MMStar [4] 指出许多评测题不看图也能答对，并人工筛选出依赖视觉的题目，用规则而非模型匹配答案。针对评测之间的冗余，Zhang 等人 [5] 用大量模型的得分相关性分析了维度内部与评测之间的重复。mmBench 与这些工作的目标不同：我们不追求覆盖面，而是让每项能力只考一种技能，以便画像中的每一项都可以单独解读。

单项能力评测。　mmBench 的题目全部来自以下公开评测集。视觉感知方面，BLINK [6] 把深度估计、对应点匹配等经典视觉任务改写为选择题；学科推理方面使用 MMMU-Pro [3]。图表方面，ChartQA [7] 以宽松准确率（数值允许 5% 误差）评测图表问答，CharXiv [8] 收集了

arXiv 论文中的真实图表并区分描述题与推理题。文档方面，DocVQA [9] 提出了扫描文档问答与 ANLS 指标（ANLS 最早见于场景文字问答 [10]），InfographicVQA [11] 关注信息图，OCRBench [12] 汇集了文字识别、场景文字问答与关键信息抽取等任务，后者包括 FUNSD [13] 与 SROIE [14] 等表单和收据数据。空间方面，Cambrian-1 [15] 提出的 CV-Bench 包含深度与距离判断，MindCube [16] 考查在有限视角下的空间心理建模。界面定位方面，ScreenSpot [17] 与其修订版 ScreenSpot-v2 [18] 覆盖手机、网页与桌面界面，ScreenSpot-Pro [19] 面向高分辨率的专业软件。视频方面，TVBench [20] 指出许多视频问答只看单帧或只看文字就能回答，并构建了真正依赖时序的题目；TimeBlind [21] 以只在时间顺序上不同的成对视频考查时序理解；MMVU [22] 则侧重专业领域知识。ZeroBench [23] 收集了当前模型几乎全部答错的视觉推理题。

统计方法。 我们用 bootstrap [24] 估计各项得分与两两差值的区间，并以题目为重抽样单位。

3 为什么要按能力过滤题目

直接把上述评测集拼在一起，并不能得到互不重叠的能力。我们逐个检查了候选来源，发现能力交叉主要有以下几类：

- **学科题里的表格、统计图与截图。** MMMU-Pro 标准版共 1730 题，按其图片类型标注，含表格的有 359 题、含统计图的有 149 题、含截图的有 9 题（一题可以有多种类型）。这些题考的主要是读表、读图与读界面，与“学科推理”应考查的能力不同。
- **感知评测中的空间与抽象推理子任务。** BLINK 的 14 个子任务中，相对深度、空间关系、多视角推理与目标定位考查的是空间关系；IQ 测试是抽象推理。
- **文档评测中的图表与照片。** DocVQA 的部分问题针对页面上的插图或照片；OCRBench 的 1000 题中，有 200 道“文档问答”直接取自 DocVQA、ChartQA 与 InfographicVQA；InfographicVQA 本身是图表与文字的混合。
- **界面定位中的文字目标与空间指点题。** 点击一段文字，本质上是“读字 + 定位”，会与文档能力重叠；反过来，若空间题用坐标作答，又会与界面定位共享“输出坐标”这一能力。
- **视频评测中的专业知识题。** 依赖专业领域知识的视频题，考查的主要是学科知识而非时序理解。

这些发现直接决定了第 4 节的过滤规则：凡是会考到其他能力的子集、题型或答题形式，一律不收。

4 mmBench 基准

4.1 设计原则

- **一项能力只考一种技能。** 题目所需的主要技能必须属于该项能力；会考到其他能力的题在抽题时排除（表 1）。
- **一项能力只用一类答题形式。** 选择、短答案、坐标等形式各自只出现在少数能力中，其中坐标只用于界面定位，避免“不会按格式作答”这一种失败同时拉低多项能力。

表 1　7 项能力的定义、来源与排除规则。括号内为题数与难度档。难度按来源对当前模型是否已经饱和划分；MMMU-Pro 使用其自带的难度标签逐题分档。

能力	考查内容	答题形式	来源（题数，难度）	排除的题
学科推理	结合学科知识的看图推理	10 选 1	MMMU-Pro 标准版（50，L1–L3）	图片为表格、统计图或截图的题；题目印在图片里的版本
视觉感知	计数、对应点、相似度、反射率、伪造检测、拼图、画风	选择题	BLINK 的 9 个子任务（54，L2）	深度、方位、多视角、定位子任务（归入空间）；IQ 测试
图表	读取数值、比较与趋势	短答案	ChartQA（15，L1）；CharXiv 推理题（35，L3）	—
文档	表单、版面、表格、收据等密集文字	短答案	DocVQA（30，L1）；OCRBench 关键信息抽取（20，L2）	针对插图或照片的问题；信息图；OCRBench 的文档问答子集
空间	深度、距离、方位与多视角心理建模	选择题	CV-Bench 3D（14，L1）；BLINK 空间子任务（16，L2）；MindCube（20，L3）	以坐标作答的指点题
界面定位	在截图上找到要点击的图标	坐标	ScreenSpot-v2（20，L1）；ScreenSpot-Pro（30，L3）	文字目标
视频时序	单看一帧无法回答的时序问题	是非、二选一	TimeBlind（50，L3）	依赖专业知识的视频题

- **所有模型答同一套题。**　题库由固定随机种子决定并以题号清单发布；视频按同一规则抽帧，所有模型看到的帧完全相同。
- **只用确定的规则评分。**　不使用模型裁判，同一份回答在任何时候都得到同一个分数。

4.2　构建流程

构建流程如图 2 所示。我们通过 Hugging Face 的 datasets-server 按行读取各来源的元数据，按表 1 的规则逐题过滤，再以固定种子（seed = 0）抽样：同一来源内按子任务或难度标签轮流抽取，使各子任务与各难度档的题数尽量均衡。只有被抽中的题才会下载图片或视频；单张超过 7 MB 的图片转为 JPEG，以满足各家接口的请求大小上限。视频按时长等分为 16 段，取每段中点的一帧，作为一组按时间排列的图片提供给模型。构建完成后，题号清单固定为 `samples/mm.json`，此后所有模型都回答这同一套题。

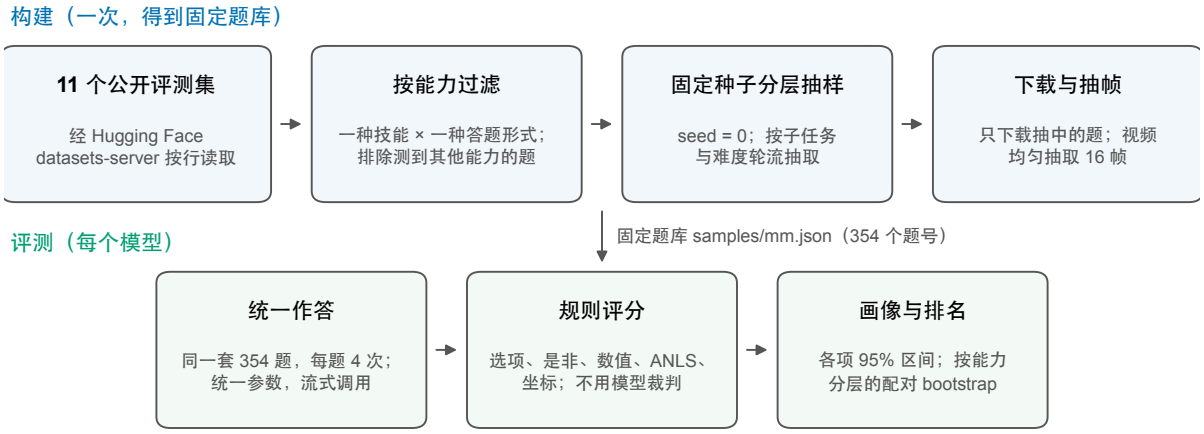


图 2　构建与评测流程。上行只执行一次，得到固定题库；下行对每个模型执行，题目、抽帧与评分规则对所有模型完全相同。

表 2　各项能力的统计信息。“随机猜测得分”为逐题计算的期望得分：选择题为选项数的倒数，是非题为 0.5，坐标题为目标框面积占整图的比例，短答案为 0。提示词词数包含作答格式说明。

能力	题数	题型（题数）	每题图片数	分辨率中位数（MP）	提示词词数	随机猜测得分
学科推理	50	选择 50	1.2	0.41	85	12.9
视觉感知	54	选择 54	2.3	0.70	40	34.3
图表	50	文字 37 / 数值 13	1.0	0.50	37	0.0
文档	50	ANLS 50	1.0	3.10	33	0.0
空间	50	选择 50	2.1	0.31	61	42.0
界面定位	50	坐标 50	1.0	3.69	53	1.3
视频时序	50	是非 25 / 选择 25	16 帧	0.92	39	50.0
合计	354	难度：L1 96 题，L2 107 题，L3 151 题				20.1（等权）

4.3　统计信息

表 2 给出了各项能力的题数、题型、图片规模与随机猜测的期望得分。题型共 6 种：选择题 179 道、ANLS 短答案 50 道、坐标 50 道、文字短答案 37 道、是非题 25 道、数值短答案 13 道。文档与界面定位的图片分辨率最高（中位数分别为 3.10 与 3.69 百万像素），视频每题 16 帧。随机猜测的期望得分在各项之间差异很大，从图表和文档的 0 到视频时序的 50，等权平均为 20.1。

5　评分与统计方法

5.1　答案抽取与评分

提示词要求模型在回答最后一行写出“Answer: …”（附录 B）。我们取回答中最后一个“Answer:”之后的内容作为最终答案，并按题型评分：

- **选择题与是非题：**　与标准答案的选项字母或 yes/no 相同得 1 分；无法唯一确定字母时视为

读不出答案。

- **数值与文字短答案：** 标准答案为数值时，取回答中的数值比较，允许带单位或 million、billion 等量级词；相对误差在 1% 内得 1 分，ChartQA 按其宽松准确率放宽到 5%。文字答案统一小写、去掉冠词与标点后要求完全相同。
- **文档短答案：** 采用 ANLS，即与最接近的标准答案的归一化编辑距离相似度，相似度低于 0.5 记 0。
- **界面定位：** 模型给出 0–1000 的相对坐标，换算到原图后落在目标框内得 1 分。

读不出答案、输出被截断或生成超时均记 0 分；接口在重试用尽后仍无回答的调用不计入，并在下次运行时重新请求。

5.2 聚合与区间

每个模型对每道题独立作答 $k = 4$ 次，题目得分取 4 次的平均（avg@4）。某项能力的得分是该项各题得分的平均，换算为 0–100；总分是 7 项能力的等权平均，不按题数加权，以免题多的能力在总分中占更大比重。

各项得分的 95% 区间来自 $B = 2000$ 次按题重抽样：每次在每项能力内部有放回地抽取同样数量的题，重新计算各项得分与总分，取 2.5% 与 97.5% 分位数。两个模型的比较采用配对 bootstrap：每次重抽样对两个模型使用同一组题，得到分差的分布，从而消除题目难度带来的共同波动。

5.3 排名规则

模型的名次定义为 1 加上“明显强于它的模型数”，其中“明显强于”指两者总分差的 95% 区间完全大于 0。两两总分差的区间包含 0 时，两个模型名次相同。我们另报告逐题比较的胜、平、负题数与精确符号检验。在本文的题量下，两两总分差的 95% 区间半宽约为 ±2.7 分，比这更小的差距无法区分。

6 实验设置

我们评测了三个模型（表 3），均通过各自厂商的国内站、以兼容 OpenAI 的接口流式调用。所有模型都不发送 temperature，使用厂商默认值；思考深度统一设为最高档（MiniMax M3.1 Flash 不能关闭思考，默认即最高档）；Kimi K3.1 Pro 与 DeepSeek Flash V4.1-1017 的输出上限设为 96,000 token，远高于实际所需，MiniMax M3.1 Flash 不设上限。图片以 base64 内嵌，置于题目文字之前；视频题在 16 帧之前加一句“下面 N 张图片是从一段视频中按时间顺序均匀抽取的帧”。全部评测于 2026 年 10 月 31 日完成，每个模型 1416 次调用（354 题 × 4 次）。

表 3　被测模型与调用设置。单价为各厂商国内站的公开标价（元 / 百万 token），依次为输入（缓存未命中）、缓存命中与输出。DeepSeek Flash V4.1-1017 在工作日 9:00–12:00 与 14:00–18:00（北京时间）为高峰价，其余时段为表中的空闲价，高峰价为空闲价的 2 倍。

模型	API 名称	思考深度	输出上限	单价（输入 / 缓存命中 / 输出）
Kimi K3.1 Pro	`kimi-k3.1-pro`	max	96,000	13 / 1.30 / 68
MiniMax M3.1 Flash	`MiniMax-M3.1-Flash`	默认（max）	不设	1 / 0.10 / 4
DeepSeek Flash V4.1-1017	`deepseek-flash`	max	96,000	1 / 0.02 / 4

表 4　主要结果（得分 0–100，越高越好 ↑）。每列最高分加粗，次高分加下划线；灰色为按题重抽样的 95% 区间。总分为 7 项能力的等权平均。

模型	学科推理	视觉感知	图表	文档	空间	界面定位	视频时序	总分
随机猜测	12.9	34.3	0.0	0.0	42.0	1.3	50.0	20.1
Kimi K3.1 Pro	**82.0**	**89.8**	**76.0**	**88.6**	**93.5**	**76.5**	**91.0**	**85.3**
95% 区间	72.0–90.5	81.9–96.3	64.0–87.5	80.1–95.4	87.5–98.5	65.0–87.0	83.0–98.0	81.9–88.6
MiniMax M3.1 Flash	75.0	73.6	73.5	84.8	71.5	57.5	85.5	74.5
95% 区间	64.0–85.0	63.9–82.4	62.0–85.0	75.0–92.7	60.5–81.5	47.0–68.0	76.5–93.0	70.6–78.2
DeepSeek Flash V4.1-1017	73.5	79.2	72.5	87.1	83.0	36.5	84.5	73.7
95% 区间	62.5–83.5	68.5–88.4	60.5–84.5	77.5–94.6	75.0–90.0	25.0–48.0	74.5–92.5	70.1–77.5

7　实验结果

7.1　主要结果

表 4 与图 3 给出了三个模型在 7 项能力上的得分与 95% 区间。

Kimi K3.1 Pro 在全部 7 项能力上得分最高，总分领先约 11 分。　它的总分为 85.3（81.9–88.6），比 MiniMax M3.1 Flash 高 10.9 分、比 DeepSeek Flash V4.1-1017 高 11.6 分，两个差值的区间都完全大于 0；逐题比较，它分别有 90 道和 79 道题更好、15 道和 8 道题更差，符号检验 $p < 0.001$。不过，它的领先并不在每一项上都显著：在图表上它与另外两个模型的差值区间都包含 0，在视频时序上与 MiniMax M3.1 Flash、在文档上与 DeepSeek Flash V4.1-1017 的差值区间也包含 0（图 4；逐项的逐题胜负见附录表 7）。

MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 总分无法区分，能力画像却明显不同。两者总分只差 0.7 分（区间 -1.9 至 $+3.5$），逐题比较 55 道更好、52 道更差，符号检验 $p = 0.85$，按排名规则并列第二。但在单项上，MiniMax M3.1 Flash 的界面定位高出 21.0 分（区间 13.5 至 29.0），DeepSeek Flash V4.1-1017 的空间高出 11.5 分（2.5 至 21.5）、文档高出 2.3 分（0.6 至 4.3）。只看总分，这两个模型完全一样；看画像，它们适合的任务并不相同。这正是我们以能力画像为先的原因。

三个模型都远高于随机水平，图表与界面定位仍是共同的短板。　随机猜测的等权总分为 20.1，三个模型高出 53.6 至 65.2 分。图表一项三个模型都只有 72.5 至 76.0 分；界面定位的差

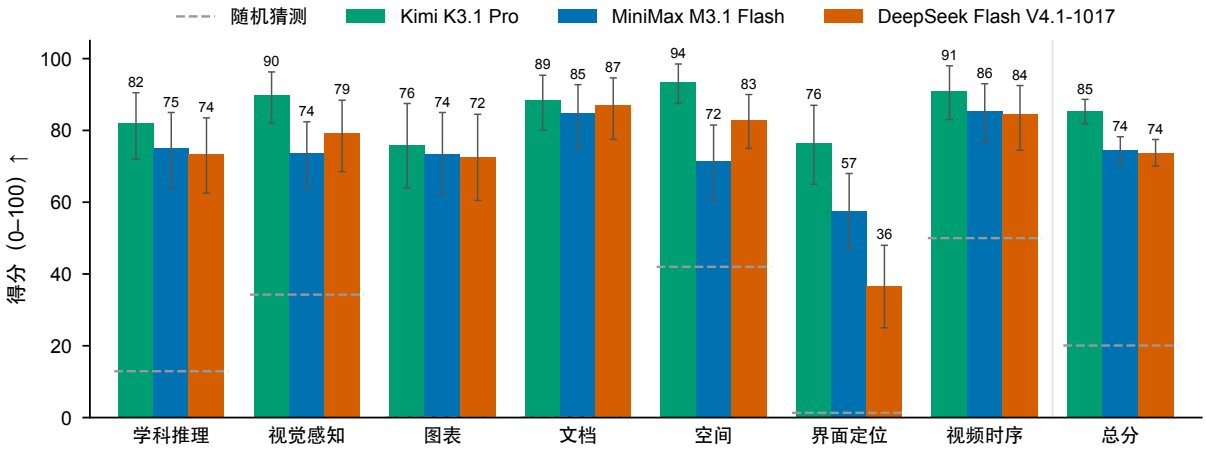


图 3　各项能力得分与 95% 区间。虚线为随机猜测的期望得分。三个模型在每一项上都明显高于随机水平；图表与界面定位离满分最远。

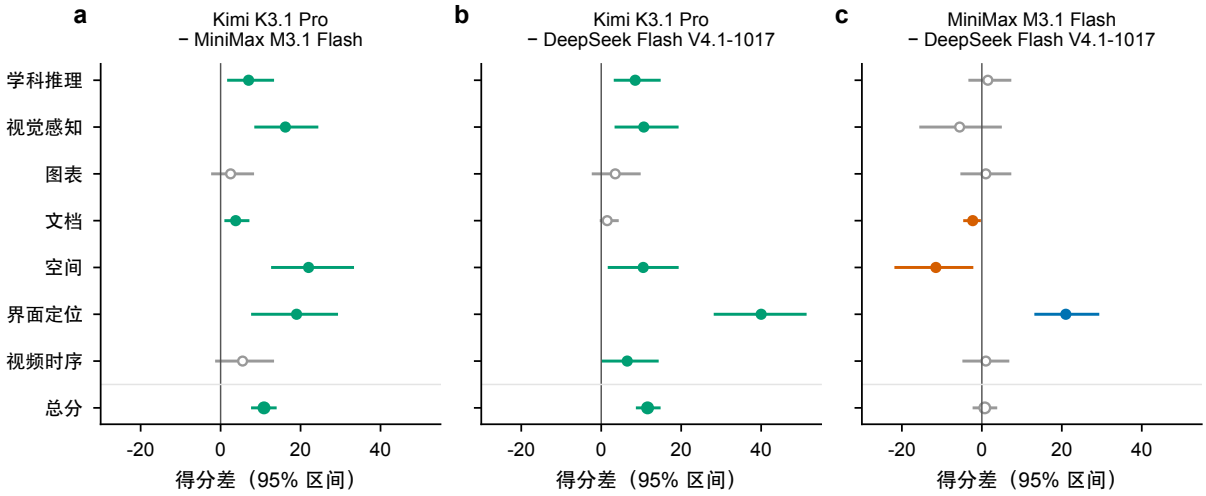


图 4　逐项两两比较。点为两个模型的得分差，横线为配对 bootstrap 的 95% 区间。实心表示区间不含 0（差异显著），空心表示区间含 0；点的颜色为该项得分更高的模型。(c) 中两个模型的总分差不显著，但界面定位与空间两项方向相反且都显著。

距最大，从 36.5 到 76.5 分，其中高分辨率专业软件（ScreenSpot-Pro）的子集上 DeepSeek Flash V4.1-1017 只有 8.3 分（附录表 6）。

7.2　难度越高，模型之间的差距是否越大?

图 5(a) 把所有能力合在一起，按难度档计算得分。在 L1 上三个模型相差不到 5 分（88.1 至 92.8），到 L3 时差距扩大到 18.2 分（61.3 至 79.5）。Kimi K3.1 Pro 从 L1 到 L3 只下降 13.3 分，MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 分别下降 24.8 与 26.8 分。需要注意的是，难度档按来源划分，不同档位对应的能力构成并不相同（例如 L3 包含全部视频题与 ScreenSpot-Pro），这里的趋势混合了难度与能力两方面的因素。

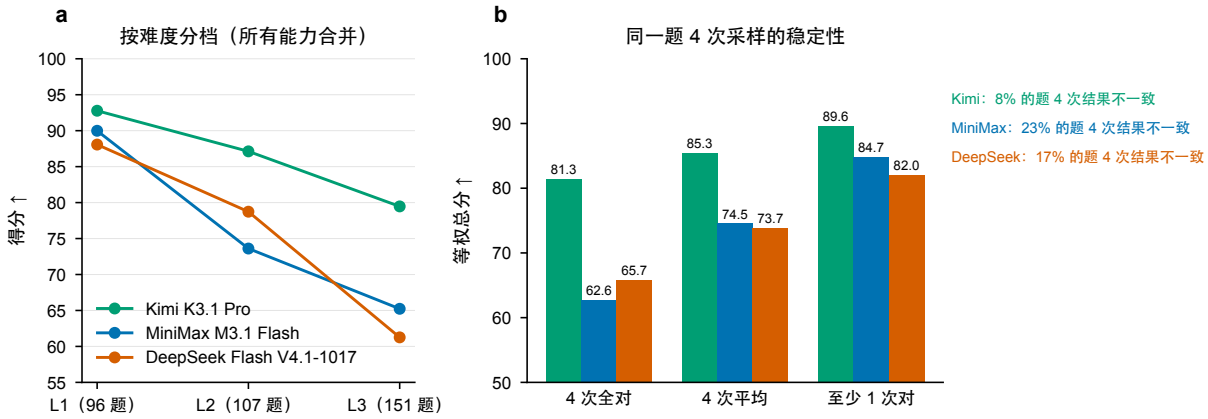


图 5　难度分档与采样稳定性。(a) 按难度档的得分（所有能力合并）。(b) 同一题 4 次采样的三种聚合：4 次全对（all@4）、4 次平均（avg@4，即本文的主指标）与至少 1 次答对（pass@4）。Kimi K3.1 Pro 的三者最接近，4 次结果不一致的题只占 8%。

表 5　token 用量与费用（越低越好↓）。token 数为各厂商接口返回的计费用量，不同厂商对同一张图片的计数方式不同，因此只有费用可以跨模型比较。费用按表 3 的国内站标价计算；DeepSeek Flash V4.1-1017 的全部调用都在空闲时段（周六），按高峰价约为 55.02 元。美元为各厂商国际站标价，仅供参考。

	每次调用平均 token					全部 1416 次调用的费用↓		
模型	输入	其中缓存命中	输出（中位数）	思考占输出	延迟中位数（秒）↓	元	元 / 题	美元参考
Kimi K3.1 Pro	5,973	425	932（221）	97.8%	11.4	192.69	0.544	$29.03
MiniMax M3.1 Flash	5,407	2,876	1,847（250）	99.3%	4.3	14.45	0.041	$2.17
DeepSeek Flash V4.1-1017	2,257	1,601	4,685（709）	99.5%	6.1	27.51	0.078	$4.13

7.3　同一道题答 4 次，结果是否稳定?

图 5(b) 比较了三种聚合方式。Kimi K3.1 Pro 只有 30 道题（8%）的 4 次结果不一致，pass@4 比 avg@4 高 4.3 分；MiniMax M3.1 Flash 有 82 道题（23%）不一致，pass@4 比 avg@4 高 10.2 分；DeepSeek Flash V4.1-1017 为 61 道题（17%）、高 8.3 分。也就是说，MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 的不少错误并非“不会”，而是“不稳定”：多次采样再投票或挑选，有望带来比 Kimi K3.1 Pro 更大的提升。这也说明单次运行的评测会给这两个模型带来更大的随机误差，每题多次采样对于可靠排名是必要的。

7.4　哪些题所有模型都答不对?

以题目得分不低于 0.5 记为答对，354 道题中有 246 道（69%）三个模型都答对，38 道（11%）三个模型都答错。全错的题集中在图表（10 道）、界面定位（8 道）与学科推理（7 道），而空间（1 道）与视频时序（2 道）最少。界面定位也是三个模型分歧最大的一项：50 道题中只有 19 道三个模型都答对。

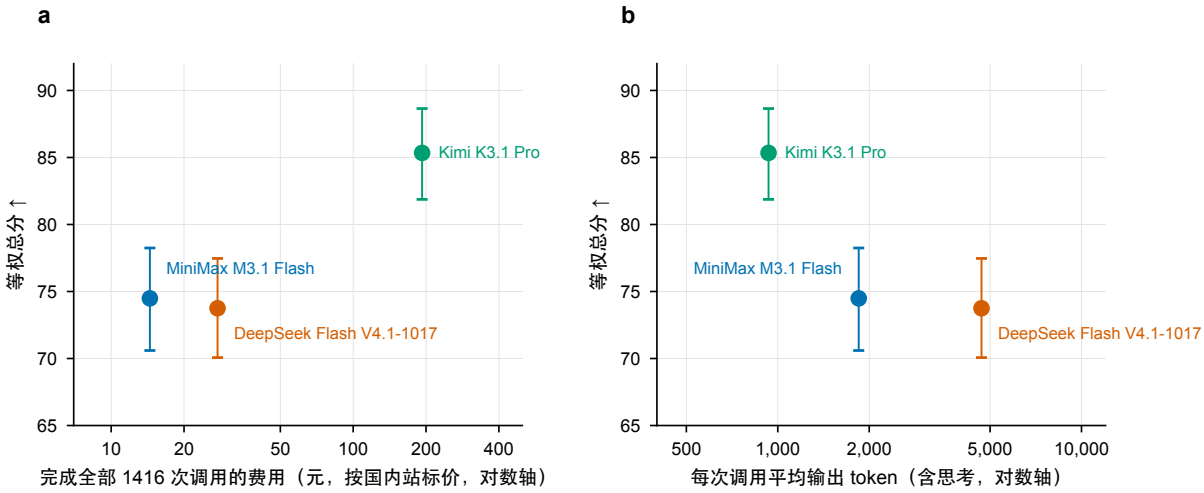


图 6　得分与费用、输出长度的关系。纵轴为等权总分及其 95% 区间。(a) 横轴为完成全部评测的费用（国内站标价）；(b) 横轴为每次调用的平均输出 token。MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 得分相当，MiniMax M3.1 Flash 的费用约为后者的一半、输出长度约为其 40%。

8　成本与 token 效率

表 5 与图 6 汇总了三个模型的 token 用量与费用。所有数字都来自接口返回的计费用量，而不是我们自己估算的 token 数。

Kimi K3.1 Pro 的领先以 7 到 13 倍的费用为代价。　按国内站标价，完成全部 1416 次调用，Kimi K3.1 Pro 约需 192.69 元，是 DeepSeek Flash V4.1-1017（27.51 元）的 7.0 倍、MiniMax M3.1 Flash（14.45 元）的 13.3 倍；折合每题（4 次作答）分别为 0.544 元、0.078 元与 0.041 元。在本次评测的一段计费窗口中，Kimi K3.1 Pro 账户的实际扣费比按标价估算的高约 17%，可能来自缓存写入等其他计费项，因此其实际费用可能更高。MiniMax M3.1 Flash 本次使用的是订阅套餐，表中为按量计费的等价费用。

输出更长并不意味着答得更好。　DeepSeek Flash V4.1-1017 每次调用平均输出 4,685 个 token，是 Kimi K3.1 Pro（932 个）的 5 倍，总分却低 11.6 分。三个模型的输出中，思考内容都占 97% 以上；输出长度的分布都有很长的尾巴，DeepSeek Flash V4.1-1017 的中位数（709）只有均值的约 15%，Kimi K3.1 Pro 的中位数更是只有 221。按能力看（图 7），DeepSeek Flash V4.1-1017 在学科推理与空间上的平均输出分别达到 9.7k 与 7.8k token，而文档题三个模型都只需 144 至 200 个 token（各项的输入与输出 token 见附录表 8）。

计费 token 不能直接跨模型比较。　三个模型看到的是完全相同的图片，接口返回的平均输入 token 却从 DeepSeek Flash V4.1-1017 的 2,257 到 Kimi K3.1 Pro 的 5,973 不等，这反映的是各家图片编码与计费方式的差异，而非模型“看”了多少内容。缓存命中的比例同样差异明显：MiniMax M3.1 Flash 平均 5,407 个输入 token 中有 2,876 个命中缓存，Kimi K3.1 Pro 只有 425 个。

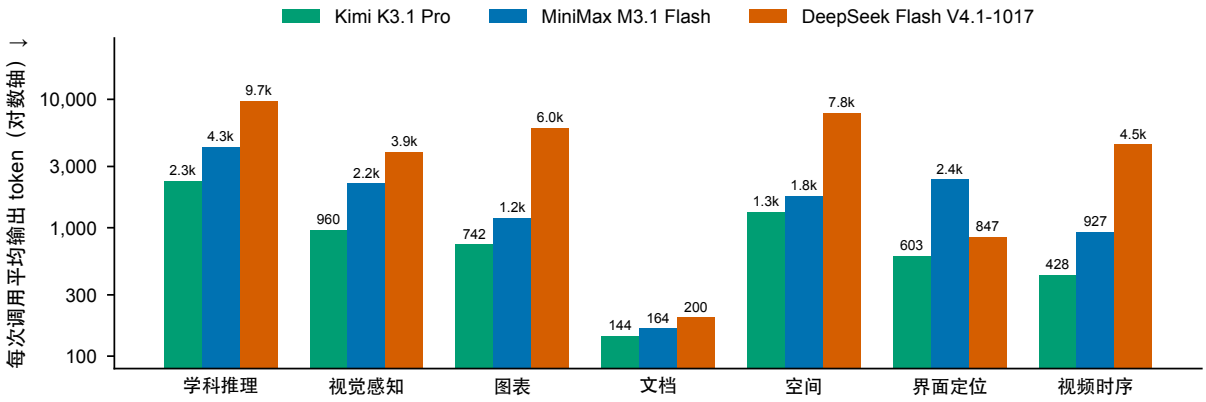


图 7　各项能力每次调用的平均输出 token（对数轴）。DeepSeek Flash V4.1-1017 在除界面定位外的每一项上输出都最长；文档题三个模型的输出都很短。

9　评分规则的鲁棒性

规则评分的风险在于：格式稍有偏差的正确回答可能被判为错。我们检查了全部 4,248 条回答（3 个模型 × 1416 次）：没有一条读不出最终答案，没有一条因输出上限被截断，也没有生成超时；界面定位的 600 条回答全部使用了要求的 0–1000 相对坐标。数值题的回答常带单位或量级词（如“51 million”），评分时按数值比较，因此不会因单位写法被误判。这说明在本文的提示词下，三个模型都能稳定地遵守作答格式，分数差异来自答案本身。

10　结论

我们提出了 mmBench，一个以能力画像为先、同时给出可量化排名的多模态评测基准。它把多模态能力划分为 7 项，每项只考一种技能、只用一类答题形式，并用规则评分、多次采样与配对 bootstrap 给出带区间的画像与排名。对三个国产模型的评测表明：Kimi K3.1 Pro 在各项上均处于领先，但代价是 7 到 13 倍的费用；MiniMax M3.1 Flash 与 DeepSeek Flash V4.1-1017 总分无法区分，却在界面定位与空间上方向相反，这类差异只有在能力画像中才能看到。后续工作包括：加入更多模型以检验能力之间是否确实独立，补充第二个视频时序来源与更高难度的题目，并加入人类基线。

局限性

- **能力的独立性是设计属性，尚未经数据验证。**　判断两项能力是否真正独立，需要在大量模型上计算得分相关性；本文只评测了 3 个模型，无法完成这一检验。
- **难度档按来源划分，未经校准。**　L1–L3 反映的是来源对当前模型的饱和程度，而非逐题测得的难度；题库中没有 L4 档。
- **部分来源接近天花板或地板。**　三个模型在 DocVQA 上都在 93.8 至 94.4 分，区分度有限；DeepSeek Flash V4.1-1017 在 ScreenSpot-Pro 上只有 8.3 分，接近地板。
- **视频只有一个来源，且以抽帧代替原生视频。**　视频时序全部来自 TimeBlind；统一的 16 帧

协议保证了可比性，但不测厂商原生的视频输入能力。

- **随机水平在各项之间不同。** 随机猜测得分从 0 到 50 不等，等权总分把这些不同起点的分数直接平均。
- **没有人类基线，评测对象有限。** 本文只评测了 3 个模型在 2026 年 10 月底的接口版本；接口模型会持续更新，结果只代表评测时的状态。
- **费用存在不确定性。** 费用按公开标价与计费 token 计算，不含可能的缓存写入等费用，也不代表订阅套餐的实际支出。

参考文献

[1] Yuan Liu, Haodong Duan, Yuanhan Zhang, et al. MMBench: Is Your Multi-modal Model an All-around Player? In *Computer Vision – ECCV 2024*, Lecture Notes in Computer Science, pages 216–233. Springer Nature Switzerland, 2024. doi: 10.1007/978-3-031-72658-3_13.

[2] Xiang Yue, Yuansheng Ni, Kai Zhang, et al. MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI. In *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9556–9567. IEEE, 2024. doi: 10.1109/cvpr52733.2024.00913.

[3] Xiang Yue, Tianyu Zheng, Yuansheng Ni, et al. MMMU-Pro: A More Robust Multi-discipline Multimodal Understanding Benchmark. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 15134–15186. Association for Computational Linguistics, 2025. doi: 10.18653/v1/2025.acl-long.736.

[4] Lin Chen, Jinsong Li, Xiaoyi Dong, et al. Are We on the Right Way for Evaluating Large Vision-Language Models? In *Advances in Neural Information Processing Systems 37*, pages 27056–27087. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2024. doi: 10.52202/079017-0850.

[5] Zicheng Zhang, Xiangyu Zhao, Xinyu Fang, et al. Redundancy Principles for MLLMs Benchmarks. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 12492–12504. Association for Computational Linguistics, 2025. doi: 10.18653/v1/2025.acl-long.612.

[6] Xingyu Fu, Yushi Hu, Bangzheng Li, et al. BLINK: Multimodal Large Language Models Can See but Not Perceive. In *Computer Vision – ECCV 2024*, Lecture Notes in Computer Science, pages 148–166. Springer Nature Switzerland, 2024. doi: 10.1007/978-3-031-73337-6_9.

[7] Ahmed Masry, Do Xuan Long, Jia Qing Tan, et al. ChartQA: A Benchmark for Question Answering about Charts with Visual and Logical Reasoning. In *Findings of the Association for Computational Linguistics: ACL 2022*, pages 2263–2279. Association for Computational Linguistics, 2022. doi: 10.18653/v1/2022.findings-acl.177.

[8] Zirui Wang, Mengzhou Xia, Luxi He, et al. CharXiv: Charting Gaps in Realistic Chart Understanding in Multimodal LLMs. In *Advances in Neural Information Processing Systems 37*, pages 113569–113697. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2024. doi: 10.52202/079017-3609.

[9] Minesh Mathew, Dimosthenis Karatzas, and C. V. Jawahar. DocVQA: A Dataset for VQA on Document Images. In *2021 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 2199–2208. IEEE, 2021. doi: 10.1109/wacv48630.2021.00225.

[10] Ali Furkan Biten, Ruben Tito, Andres Mafla, et al. Scene Text Visual Question Answering. In *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4290–4300. IEEE, 2019. doi: 10.1109/iccv.2019.00439.

[11] Minesh Mathew, Viraj Bagal, Rubèn Pérez Tito, et al. InfographicVQA. In *2022 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 2582–2591. IEEE, 2022. doi: 10.1109/wacv51458.2022.00264.

[12] Yuliang Liu, Zhang Li, Mingxin Huang, et al. OCRBench: On the Hidden Mystery of OCR in Large Multimodal Models. *Science China Information Sciences*, 67(12):220102, 2024. doi: 10.1007/s11432-024-4235-6.

[13] Guillaume Jaume, Hazim Kemal Ekenel, and Jean-Philippe Thiran. FUNSD: A Dataset for Form Understanding in Noisy Scanned Documents. In *2019 International Conference on Document Analysis and Recognition Workshops (ICDARW)*, pages 1–6. IEEE, 2019. doi: 10.1109/icdarw.2019.10029.

[14] Zheng Huang, Kai Chen, Jianhua He, et al. ICDAR2019 Competition on Scanned Receipt OCR and Information Extraction. In *2019 International Conference on Document Analysis and Recognition (ICDAR)*, pages 1516–1520. IEEE, 2019. doi: 10.1109/icdar.2019.00244.

[15] Shengbang Tong, Ellis Brown, Penghao Wu, et al. Cambrian-1: A Fully Open, Vision-Centric Exploration of Multimodal LLMs. In *Advances in Neural Information Processing Systems 37*, pages 87310–87356. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2024. doi: 10.52202/079017-2771.

[16] Qineng Wang, Baiqiao Yin, Pingyue Zhang, et al. MindCube: Spatial Mental Modeling from Limited Views. arXiv preprint arXiv:2506.21458, 2025.

[17] Kanzhi Cheng, Qiushi Sun, Yougang Chu, et al. SeeClick: Harnessing GUI Grounding for Advanced Visual GUI Agents. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 9313–9332. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.acl-long.505.

[18] Zhiyong Wu, Zhenyu Wu, Fangzhi Xu, et al. OS-ATLAS: A Foundation Action Model for Generalist GUI Agents. arXiv preprint arXiv:2410.23218, 2024.

[19] Kaixin Li, Ziyang Meng, Hongzhan Lin, et al. ScreenSpot-Pro: GUI Grounding for Professional High-Resolution Computer Use. In *Proceedings of the 33rd ACM International Conference on Multimedia*, pages 8778–8786. ACM, 2025. doi: 10.1145/3746027.3755688.

[20] Daniel Cores, Michael Dorkenwald, Manuel Mucientes, et al. Lost in Time: A New Temporal Benchmark for VideoLLMs. arXiv preprint arXiv:2410.07752, 2024.

[21] Baiqi Li, Kangyi Zhao, Ce Zhang, et al. TimeBlind: A Spatio-Temporal Compositionality Benchmark for Video LLMs. In *Proceedings of the 2026 Conference on Empirical Methods in Natural Language Processing*, pages 43801–43822. Association for Computational Linguistics, 2026. doi: 10.18653/2026.emnlp-main.1923.

[22] Yilun Zhao, Haowei Zhang, Lujing Xie, et al. MMVU: Measuring Expert-Level Multi-Discipline Video Understanding. In *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8475–8489. IEEE, 2025. doi: 10.1109/cvpr52734.2025.00793.

[23] Jonathan Roberts, Mohammad Reza Taesiri, Ansh Sharma, et al. ZeroBench: An Impossible Visual Benchmark for Contemporary Large Multimodal Models. In *International Conference on Machine Learning (ICML)*, 2026.

[24] B. Efron. Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1):1–26, 1979. doi: 10.1214/aos/1176344552.

A 各来源得分

表 6 各来源子集上的得分（↑）。每行最高分加粗，次高分加下划线；"随机"为随机猜测的期望得分。各来源只是抽样子集，得分不等于该评测集的完整成绩，也不能与其官方榜单直接比较。

能力	来源	难度	题数	随机	Kimi K3.1 Pro	MiniMax M3.1 Flash	DeepSeek Flash V4.1-1017
学科推理	MMMU-Pro	L1/L2/L3	50	12.9	**82.0**	75.0	73.5
视觉感知	BLINK	L2	54	34.3	**89.8**	73.6	79.2
图表	ChartQA	L1	15	0.0	**86.7**	**86.7**	**86.7**
图表	CharXiv	L3	35	0.0	**71.4**	67.9	66.4
文档	DocVQA	L1	30	0.0	**94.4**	93.8	94.3
文档	OCRBench-KIE	L2	20	0.0	**79.9**	71.3	76.2
空间	CV-Bench-3D	L1	14	50.0	**98.2**	92.9	**98.2**
空间	BLINK 空间子任务	L2	16	50.0	**87.5**	71.9	79.7
空间	MindCube	L3	20	30.0	**95.0**	56.2	75.0
界面定位	ScreenSpot-v2	L1	20	3.3	**100.0**	91.2	78.8
界面定位	ScreenSpot-Pro	L3	30	0.0	**60.8**	35.0	8.3
视频时序	TimeBlind	L3	50	50.0	**91.0**	85.5	84.5

表 7　逐项两两比较的逐题胜、平、负题数与得分差。以题目的 4 次平均分比较；* 表示配对 bootstrap 的 95% 区间不含 0。

	Kimi − MiniMax		Kimi − DeepSeek		MiniMax − DeepSeek	
能力	胜 / 平 / 负	分差	胜 / 平 / 负	分差	胜 / 平 / 负	分差
学科推理	9 / 39 / 2	+7.0*	11 / 39 / 0	+8.5*	4 / 42 / 4	+1.5
视觉感知	18 / 34 / 2	+16.2*	8 / 45 / 1	+10.6*	9 / 31 / 14	-5.6
图表	5 / 43 / 2	+2.5	5 / 42 / 3	+3.5	6 / 39 / 5	+1.0
文档	9 / 41 / 0	+3.8*	4 / 45 / 1	+1.5	2 / 41 / 7	-2.3*
空间	20 / 29 / 1	+22.0*	14 / 34 / 2	+10.5*	6 / 29 / 15	-11.5*
界面定位	21 / 23 / 6	+19.0*	30 / 20 / 0	+40.0*	24 / 23 / 3	+21.0*
视频时序	8 / 40 / 2	+5.5	7 / 42 / 1	+6.5*	4 / 42 / 4	+1.0
全部	90 / 249 / 15	+10.9*	79 / 267 / 8	+11.6*	55 / 247 / 52	+0.7

表 8　各项能力每次调用的平均输入与输出 token。token 数为各厂商的计费用量，跨厂商不可直接比较。

	Kimi K3.1 Pro		MiniMax M3.1 Flash		DeepSeek Flash V4.1-1017	
能力	输入	输出	输入	输出	输入	输出
学科推理	1,231	2,318	1,236	4,267	615	9,700
视觉感知	3,172	960	3,148	2,211	1,349	3,888
图表	929	742	1,040	1,191	464	5,964
文档	3,729	144	2,856	164	844	200
空间	1,226	1,328	1,329	1,762	686	7,810
界面定位	6,283	603	2,962	2,377	1,048	847
视频时序	25,464	428	25,459	927	10,862	4,451

B　提示词

每道题的提示词由题目、选项（若有）与作答格式说明三部分组成，以空行分隔；图片或视频帧位于文字之前。作答格式说明按题型取以下四种之一（原文为英文）：

- 选择题：`Answer with the letter of the correct option. End your reply with a line of the form "Answer: X".`
- 是非题：`Answer yes or no. End your reply with a line of the form "Answer: yes" or "Answer: no".`
- 短答案：`Answer with a single word, number or short phrase. End your reply with a line of the form "Answer: <your answer>".`
- 坐标：`Give the point as relative coordinates: x from the left edge and y from the top edge of the image, each an integer from 0 to 1000. End your`

reply with a line of the form "Answer: (x, y)".

选择题的选项以“A. …”“B. …”的形式逐行列出；选项已写在题目中或图片中的题不再重复列出。视频题在帧之前加一句：The following 16 images are frames sampled uniformly from a video, in order.

C 复现

代码、题号清单与本文的全部图表脚本见 https://github.com/BAI-AI-Lab/mmBench。题目、图片与视频帧不随仓库发布，需按以下命令从原始来源重新构建（在来源数据集未变动的前提下，固定种子保证得到同一套题；仓库的每周 CI 会检查各来源是否仍可访问并能抽满题数）：

```
bash install.sh                      # Python 环境
bin/mmb build                        # 按来源与 seed = 0 构建题库
export MODEL=... OPENAI_BASE_URL=... OPENAI_API_KEY=...
REASONING_EFFORT=max bin/mmb run     # 每题 4 次，结束后生成单模型报告
bin/mmb report runs/A/mm-full runs/B/mm-full --out reports/A_vs_B
```

运行中断后重跑同一条命令只补未完成的题；同一运行目录同一时间只允许一个进程，避免重复请求。本文的分析数字、表格与图由仓库 paper 目录下的三个脚本从各运行的日志生成：analysis.py 计算全部统计量，make_tables.py 生成表格，make_figures.py 绘图。