mmBench 多模态评测报告

MiniMax M3.1 Flash / DeepSeek Flash V4.1-1017 / Kimi K3.1 Pro

2026-10-31

1 总结

在 354 道题（7 项能力：学科推理、视觉感知、图表、文档、空间、界面定位、视频时序）上，按各项等权的总分：第 1 名 Kimi K3.1 Pro 85.3（81.9–88.6）；第 2 名 MiniMax M3.1 Flash 74.5（70.6–78.2）；第 2 名 DeepSeek Flash V4.1-1017 73.7（70.1–77.5）（括号内为 95% 区间）。Kimi K3.1 Pro 比 MiniMax M3.1 Flash 高 10.9 分（区间 +8.0 至 +13.7），差距显著；逐题比较 90 题更好、15 题更差、249 题相同（符号检验 $p < 0.001$）。MiniMax M3.1 Flash 比 DeepSeek Flash V4.1-1017 高 0.7 分（区间 -1.9 至 +3.5），区间包含 0，判为平手；逐题比较 55 题更好、52 题更差、247 题相同（符号检验 $p = 0.847$）。Kimi K3.1 Pro 最强的是空间（93.5），最弱的是图表（76.0）。MiniMax M3.1 Flash 最强的是视频时序（85.5），最弱的是界面定位（57.5）。DeepSeek Flash V4.1-1017 最强的是文档（87.1），最弱的是界面定位（36.5）。

说明：

- 每道题每个模型答 4 次，题目得分取各次的平均；只比较所有模型都答过的 354 道题。题目抽自公开评测集，按来源的难度分为 L1–L4，分数不能和这些评测集的官方榜单直接比较。
- 总分是各项能力的等权平均，不按题数加权。95% 区间来自 2000 次按题重抽样（bootstrap）；两两差值的区间在每项能力内成对重抽样。区间包含 0 的两个模型判为平手，名次相同。
- 按这套题的题量，两两总分差的 95% 区间半宽约 ±2.7 分：比这小的差距分不出来。
- MiniMax M3.1 Flash：max_tokens 不设上限，temperature 用厂商默认值。
- DeepSeek Flash V4.1-1017：reasoning_effort = max，max_tokens = 96000，temperature 用厂商默认值。
- Kimi K3.1 Pro：reasoning_effort = max，max_tokens = 96000，temperature 用厂商默认值。

2 模型简介

各模型的发布信息、相较上一版的更新与亮点，整理自厂商公告与模型卡；标注“厂商自报”的分数未经独立复现，与本报告的测评结果不是同一口径。

MiniMax M3.1 Flash

项目	内容
厂商	MiniMax
发布	2026-09-27 以 M3.1-Flash-Preview 在 MiniMax Code 内测；2026-10-19 正式上线 API；2026-10-23 放出权重
权重与许可	开放权重，MiniMax Community License（商用须标注；年收入 2000 万美元以上须书面授权）
架构	MoE：总参数约 428B、每 token 激活约 23B（与 M3 同规模），官方称采用更激进的稀疏化；上下文 1M；输入文本、图像、视频；思考不能关闭，深度用 reasoning_effort 调（默认 max）
价格	每百万 token 输入 $0.15、缓存 $0.015、输出 $0.60，不分时段、不分上下文长度（国内站 ¥1 / ¥0.1 / ¥4）
本次调用	MiniMax 官方 API（国内站，OpenAI 兼容接口）

相较上一版的更新：

- 官方称在线推理速度快了近 3 倍，智能体任务的整体使用成本比前代低 70%（博客未点名前代）；输出速度可达 200+ token/s，P50 在 170+
- 2026-10-19 起 MiniMax 把 M2.5、M2.7 归为旧版，套餐内对它们的请求自动改由 M3.1 Flash 处理

亮点：

- 定位智能体任务：长程软件工程、电脑操作、企业流程自动化、网络安全
- 厂商自报 DeepSWE v1.1 73.7%、OSWorld V2 61.7、Agents' Last Exam 29.6、CyberGym 82%
- 单价是同档最低的一批；第三方测评提示其幻觉率偏高，答案需要核验

资料来源：MiniMax 官方博客：M3.1 Flash；MiniMax 接口文档；权重与许可（OrcaRouter 汇总）；VentureBeat：幻觉率

DeepSeek Flash V4.1-1017

项目	内容
厂商	DeepSeek
发布	V4.1-Flash 2026-09-10 发布；2026-10-17 更新为 1017 版（API 名 deepseek-flash 与价格不变）
权重与许可	开放权重，MIT 许可
架构	多模态 MoE：主干 552B 参数，每 token 激活 8B（prefill）/ 16B（decode），另有 196B Engram 条件记忆；上下文 1M；支持图像输入
价格	每百万 token 输入 $0.30、缓存命中 $0.006、输出 $1.20；北京时间非高峰时段半价
本次调用	DeepSeek 官方 API

相较上一版的更新：

- 1017 版相较 9 月版：官方称缩短了任务耗时和输出长度；厂商自报 Terminal-Bench 4.0 31.2 → 42.3、DeepSWE v1.1 74.2 → 77.0、ProgramBench 20.3 → 29.1、NL2Repo-Bench 65.4 → 68.2、HLE

（无工具）36.8 → 42.6

- V4.1 代相较 V4-Flash：新架构系列里最小的模型，原生支持视觉理解；持久 KV cache 约为 V4-Flash 的 1/8，全局 KV cache 每 token 890 字节、约为 1/4；Codeforces 评分 3289 → 3471（厂商自报，各次测评环境不完全相同）

亮点：

- 开放权重、MIT 许可，单价在同档里偏低，非高峰再打对折
- 1M 上下文，思考深度可调（API 提供 low / high / max）
- 厂商自报 DeepSWE v1.1 77.0、Terminal-Bench 4.0 42.3，偏重智能体编程

资料来源：DeepSeek API 更新日志；DeepSeek-V4.1-Flash 模型卡

3 能力画像

每项能力的得分是该项各题得分的平均（0–100）。

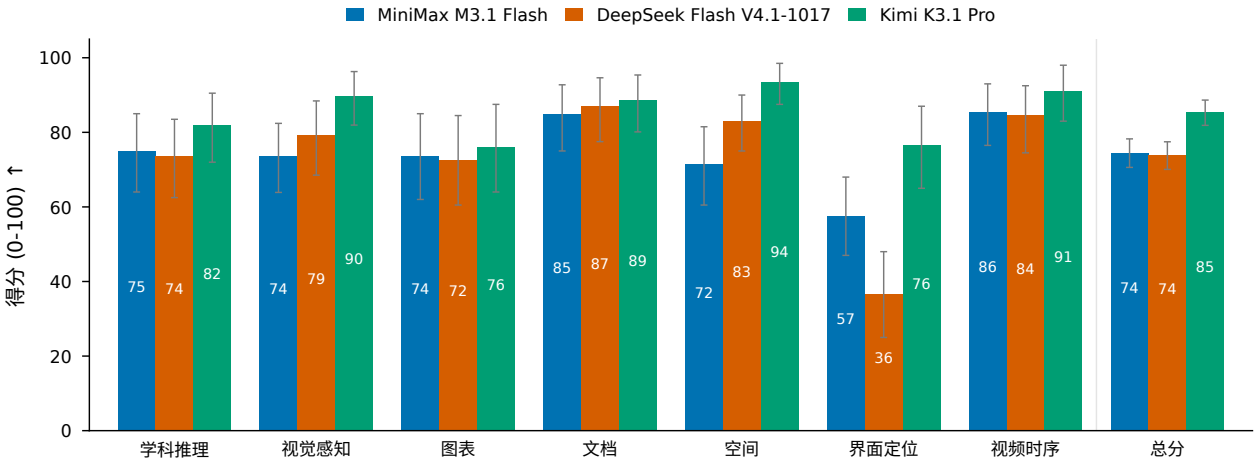


图 1: 各项能力得分（误差线为 95% 区间）

		得分（0–100，括号内 95% 区间）↑		
能力	题数	MiniMax M3.1 Flash	DeepSeek Flash V4.1-1017	Kimi K3.1 Pro
学科推理	50	75.0（64.0–85.0）	73.5（62.5–83.5）	82.0（72.0–90.5）
视觉感知	54	73.6（63.9–82.4）	79.2（68.5–88.4）	89.8（81.9–96.3）
图表	50	73.5（62.0–85.0）	72.5（60.5–84.5）	76.0（64.0–87.5）
文档	50	84.8（75.0–92.7）	87.1（77.5–94.6）	88.6（80.1–95.4）
空间	50	71.5（60.5–81.5）	83.0（75.0–90.0）	93.5（87.5–98.5）
界面定位	50	57.5（47.0–68.0）	36.5（25.0–48.0）	76.5（65.0–87.0）
视频时序	50	85.5（76.5–93.0）	84.5（74.5–92.5）	91.0（83.0–98.0）
总分（等权）	354	74.5（70.6–78.2）	73.7（70.1–77.5）	85.3（81.9–88.6）

4 排名

名次 = 1 + 明显强于它的模型数；区间包含 0 的模型名次相同。

名次	模型	总分 ↑
1	Kimi K3.1 Pro	85.3（81.9–88.6）
2	MiniMax M3.1 Flash	74.5（70.6–78.2）
2	DeepSeek Flash V4.1-1017	73.7（70.1–77.5）

两两比较：总分差与 95% 区间；逐题比较的胜、负、平题数与符号检验。

比较	总分差	95% 区间	胜	负	平	p
Kimi K3.1 Pro – MiniMax M3.1 Flash	+10.9	+8.0 至 +13.7	90	15	249	< 0.001
Kimi K3.1 Pro – DeepSeek Flash V4.1-1017	+11.6	+9.0 至 +14.5	79	8	267	< 0.001
MiniMax M3.1 Flash – DeepSeek Flash V4.1-1017	+0.7	-1.9 至 +3.5	55	52	247	0.847

5 按难度

各档的题来自不同评测集（见下表），这里把所有能力合在一起按题平均。

		得分 ↑		
难度	题数	MiniMax M3.1 Flash	DeepSeek Flash V4.1-1017	Kimi K3.1 Pro
L1 基础	96	90.0	88.1	92.8
L2 中等	107	73.6	78.7	87.1
L3 困难	151	65.2	61.3	79.5

6 按来源

每个来源评测集上的得分，只是抽样的子集，不等于该评测集的完整成绩。

				得分 ↑		
能力	来源	难度	题数	MiniMax M3.1 Flash	DeepSeek Flash V4.1-1017	Kimi K3.1 Pro
学科推理	mmmu_pro	L1/L2/L3	50	75.0	73.5	82.0
视觉感知	blink	L2	54	73.6	79.2	89.8
图表	chartqa	L1	15	86.7	86.7	86.7
图表	charxiv	L3	35	67.9	66.4	71.4
文档	docvqa	L1	30	93.8	94.3	94.4
文档	ocrbench_kie	L2	20	71.3	76.2	79.9
空间	blink_spatial	L2	16	71.9	79.7	87.5
空间	cvbench_3d	L1	14	92.9	98.2	98.2
空间	mindcube	L3	20	56.2	75.0	95.0
界面定位	screenspot_pro	L3	30	35.0	8.3	60.8
界面定位	screenspot_v2	L1	20	91.2	78.8	100.0
视频时序	timeblind	L3	50	85.5	84.5	91.0

7 成本与速度

模型	调用次数	平均输入 token ↓	平均输出 token ↓	延迟中位数 s ↓	总费用 ↓	每题费用 ↓
MiniMax M3.1 Flash	1416	5.4k	1.8k	4	$2.17	$0.006
DeepSeek Flash V4.1-1017	1416	2.3k	4.7k	6	$8.25	$0.023
Kimi K3.1 Pro	1416	6.0k	0.9k	11	–	–

8 评分规则

题型	怎么判
选择题	取回答最后一行“Answer: X”中的选项字母，与标准答案相同得 1 分
是 / 否	取最后的 yes 或 no，与标准答案相同得 1 分
短答案	标准答案是数字时，取回答里的数（可以带单位或 million、billion 等量级词，按量级换算或不换算都算），相对误差 1% 内（ChartQA 按其规则放宽到 5%）得 1 分；文字答案规范化（小写、去冠词和标点）后完全相同得 1 分
文档问答	ANLS：与最接近的标准答案的归一化编辑距离相似度，低于 0.5 记 0（DocVQA 的规则）
界面定位	模型给出 0–1000 的相对坐标，换算到原图后落在目标框内得 1 分
视频	所有模型都拿到同样的若干帧（按时间均匀抽取的图片），按上面的题型判分

由 Albert Huang 创建于 2026-10-31